

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



przedmiot
PPMGR - Pracownia Problemowa Magisterska



Badanie bezpieczeństwa agentów AI w aplikacjach
Analiza literatury i sytuacji na rynku protokołu MCP

Andrzej Pultyn

Numer albumu 325213

prowadzący
dr inż. Sławomir Kukliński

WARSZAWA 9 maja 2026

Spis treści

1. Wprowadzenie	3
2. Architektura MCP	4
3. Bezpieczeństwo protokołu MCP	4
4. Przyszłość protokołu MCP	5
5. Potencjalne kierunki badawcze	5
Bibliografia	7


1. Wprowadzenie

Protokół MCP (ang. *Model Context Protocol*) jest standardem *open-source*, udostępnionym przez firmę Anthropic w listopadzie 2024 roku [1]. Wg. firmy OpenAI stał się najbardziej rozpowszechnionym rozwiązaniem do rozszerzania możliwości modeli AI o dodatkową wiedzę i narzędzia [2]. Mimo że nie ma ogólnie dostępnego licznika wywołań MCP, liczby takie jak ponad 10 tysięcy aktywnych publicznych serwerów MCP, czy ponad 97 milionów pobranych SDK dla języków Python i TypeScript (stan na 9 grudnia 2025) [3] potwierdzają takie stwierdzenie.


Aby zrozumieć motywację do jego powstania, należy zacząć od dużych modeli językowych (LLM - ang. *Large Language Models*). Są one rodzajem sieci neuronowych, trenowanych na dużych zbiorach danych do rozwiązywania zadań związanych z przetwarzaniem języka naturalnego. Posiadają jednak istotne ograniczenia. Pierwszym z nich jest ograniczona wiedza. Najbardziej aktualnymi informacjami które model może posiadać są te z momentu jego treningu, nie później. Dzięki temu pierwsze ogólnie dostępne modele podawały przestarzałe informacje. Drugim ograniczeniem jest precyzja obliczeń. O ile proste obliczenia mogą być wykonywane poprawnie na podstawie danych treningowych, to przy bardziej złożonych zadaniach LLM-y mają duże problemy.

Powyższe problemy, jak i chęć rozszerzenia możliwości sztucznej inteligencji ponad zwykłe odpowiadania na pytania, zmotywowało deweloperów do pierwszych integracji dużych modeli językowych z zewnętrznymi narzędziami, które mogłyby wykonać problematyczne zadania. Na początku konieczne było pisanie kodu dla każdej pary spośród M modeli AI i N narzędzi, co dawało $M \times N$ integracji (patrz rys. 1.1). Wykorzystując protokół MCP, każdy model AI musi zaimplementować po jednym i każde narzędzie jeden serwer, co zmniejsza ilość integracji do $M + N$ (patrz rysunek 1.2)[4].

Rysunek 1.1. Schemat integracji $M \times N$ (przed protokołem MCP)



Rysunek 1.2. Schemat integracji $M + N$ (wykorzystując protokół MCP)



2. Architektura MCP

Rozwiązanie MCP składa się z trzech głównych rodzajów komponentów:

- gospodarzy (ang. *MCP Host*) - aplikacji AI koordynujących i zarządzających klientami MCP,
- klientów (ang. *MCP Client*) - komponentów łączących się z serwerami i pozyskujących kontekst dla gospodarzy,
- serwerów (ang. *MCP Server*) - programów dostarczających kontekst dla klientów.

Standard definiuje trzy rodzaje usług, które serwer może udostępnić klientowi (ang. *primitives*). Pierwszym są **narzędzia** (ang. *tools*). Są to funkcje wołane przez aplikację AI, umożliwiające im wykonanie konkretnej akcji. Każda funkcja ma jasno zdefiniowane wejścia i wyjścia w formacie JSON. Przykładowa konfiguracja, zasoby (ang. *resources*) - pasywne źródła danych dające dodatkowy kontekst dla aplikacji AI, prompty (ang. *prompts*) - szablony zapytań ułatwiających interakcje z modelami językowymi.

Każdy rodzaj usługi ma zdefiniowane metody `*/list` do wyszukiwania dostępnych zasobów, `*/get` do ich pozyskania, a w przypadku narzędzi - `tools/call` do ich wywołania.

[5]

3. Bezpieczeństwo protokołu MCP

Wraz z rozwojem generatywnej sztucznej inteligencji i jej adopcji przez firmy, zapotrzebowanie na identyfikację najpopularniejszych podatności i, przede wszystkim, sposobów im przeciwdziałania, rosło. Jedną z pierwszych inicjatyw w tym kierunku był projekt *OWASP Top 10 for LLM Applications* [6], rozpoczęty w maju 2023 roku. Okazał się ogromnym sukcesem. Na początku roku 2024 zaangażowane w niego było ponad 600

ekspertów z ponad 18 krajów, ponad 130 firm i prawie 8000 aktywnych członków [7]. Z czasem projekt ewoluował w bardziej ogólny projekt *OWASP GenAI Security Project*, zajmujący się identyfikacją, mitygacją oraz dokumentacją bezpieczeństwa oraz zagrożeń związanych z generatywną sztuczną inteligencją.

Jednym z podprojektów uruchomionych w ramach *OWASP GenAI Security Project* jest *OWASP MCP Top 10*, skoncentrowany wyłącznie na zagrożeniach związanych z protokołem MCP [8]. W maju 2026 roku znajduje się on w fazie trzeciej z pięciu. Została wydana pierwsza wersja dziesięciu najważniejszych podatności i zbierane są opinie społeczności na ich temat. Następna faza przewiduje wydanie pierwszej oficjalnej listy top 10 oraz cykliczne jej aktualizowanie, tak jak ma to miejsce dla innych list *OWASP Top 10* [9].

Na szczycie obecnej listy podatności dla protokołu MCP jest **błędne zarządzanie tokenami i wyciek sekretów** (ang. *Token Mismanagement and Secret Exposure*). Dotyczy to sytuacji, w których deweloperzy nie zabezpieczają odpowiednio sekretów, służących do uwierzytelnienia i autoryzacji pomiędzy modelami, narzędziami i serwerami. Może to doprowadzić do wykonania nieautoryzowanych operacji, a nawet przejęcia części lub całości infrastruktury.

Na drugim miejscu znajduje się **eskalacja uprawnień przez rozszerzanie zakresu działania** (ang. *Privilege Escalation via Scope Creep*).

4. Przyszłość protokołu MCP

5. Potencjalne kierunki badawcze

Bibliografia

- [1] Anthropic, “Introducing the Model Context Protocol”, Dostęp zdalny (6.05.2026): <https://www.anthropic.com/news/model-context-protocol>, 2024.
- [2] OpenAI, “Dokumentacja API OpenAI”, Dostęp zdalny (7.05.2026): <https://developers.openai.com/api/docs/mcp>.
- [3] Anthropic, “Donating the Model Context Protocol and establishing the Agentic AI Foundation”, Dostęp zdalny (7.05.2026): <https://www.anthropic.com/news/donating-the-model-context-protocol-and-establishing-of-the-agentic-ai-foundation>, 2025.
- [4] Y. Lei i in., “A Comprehensive Survey on Model Context Protocol: Architecture, Tool Integration, and the Future of AI Interoperability”, Dostęp zdalny (9.05.2026): <https://ssrn.com/abstract=5957238>, 2025.
- [5] M. C. Protocol, “Architecture Overview”, Dostęp zdalny (9.05.2026): <https://modelcontextprotocol.io/docs/learn/architecture>.
- [6] OWASP, “OWASP Top 10 for Large Language Model Applications”, Dostęp zdalny (9.05.2026): <https://owasp.org/www-project-top-10-for-large-language-model-applications/>.
- [7] O. G. S. Project, “OWASP Gen AI Security Project Introduction and Background”, Dostęp zdalny (9.05.2026): <https://genai.owasp.org/introduction-genai-security-project/>.
- [8] OWASP, “Repozytorium GitHub projektu OWASP MCP Top 10”, Dostęp zdalny (9.05.2026): <https://github.com/OWASP/www-project-mcp-top-10/tree/main>.
- [9] OWASP, “OWASP MCP Top 10”, Dostęp zdalny (9.05.2026): <https://owasp.org/www-project-mcp-top-10/>.