

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



przedmiot
PPMGR - Pracownia Problemowa Magisterska



Badanie bezpieczeństwa agentów AI w aplikacjach
Analiza literatury i sytuacji na rynku protokołu MCP

Andrzej Pultyn

Numer albumu 325213

prowadzący
dr inż. Sławomir Kukliński

WARSZAWA 9 maja 2026

Spis treści

1. Wprowadzenie	3
2. Architektura MCP	4
3. Bezpieczeństwo protokołu MCP	4
4. Przyszłość protokołu MCP	4
5. Potencjalne kierunki badawcze	4
Bibliografia	5
Spis załączników	5


1. Wprowadzenie

Protokół MCP (ang. *Model Context Protocol*) jest standardem *open-source*, udostępnionym przez firmę Anthropic w listopadzie 2024 roku [1]. Wg. firmy OpenAI stał się najbardziej rozpowszechnionym rozwiązaniem do rozszerzania możliwości modeli AI o dodatkową wiedzę i narzędzia [2]. Mimo że nie ma ogólnie dostępnego licznika wywołań MCP, liczby takie jak ponad 10 tysięcy aktywnych publicznych serwerów MCP, czy ponad 97 milionów pobranych SDK dla języków Python i TypeScript (stan na 9 grudnia 2025) [3] potwierdzają takie stwierdzenie.


Aby zrozumieć motywację do jego powstania, należy zacząć od dużych modeli językowych (LLM - ang. *Large Language Models*). Są one rodzajem sieci neuronowych, trenowanych na dużych zbiorach danych do rozwiązywania zadań związanych z przetwarzaniem języka naturalnego. Posiadają jednak istotne ograniczenia. Pierwszym z nich jest ograniczona wiedza. Najbardziej aktualnymi informacjami które model może posiadać są te z momentu jego treningu, nie później. Dzięki temu pierwsze ogólnie dostępne modele podawały przestarzałe informacje. Drugim ograniczeniem jest precyzja obliczeń. O ile proste obliczenia mogą być wykonywane poprawnie na podstawie danych treningowych, to przy bardziej złożonych zadaniach LLM-y mają duże problemy.

Powyższe problemy, jak i chęć rozszerzenia możliwości sztucznej inteligencji ponad zwykłe odpowiadania na pytania, zmotywowało deweloperów do pierwszych integracji dużych modeli językowych z zewnętrznymi narzędziami, które mogłyby wykonać problematyczne zadania. Na początku konieczne było pisanie kodu dla każdej pary spośród M modeli AI i N narzędzi, co dawało $M \times N$ integracji (patrz rys. 1.1). Wykorzystując protokół MCP, każdy model AI musi zaimplementować po jednym i każde narzędzie jeden serwer, co zmniejsza ilość integracji do $M + N$ (patrz rysunek 1.2)[4].

Rysunek 1.1. Schemat integracji $M \times N$ (przed protokołem MCP)



Rysunek 1.2. Schemat integracji $M + N$ (wykorzystując protokół MCP)



2. Architektura MCP

3. Bezpieczeństwo protokołu MCP

4. Przyszłość protokołu MCP

5. Potencjalne kierunki badawcze

Bibliografia

- [1] Anthropic, “Introducing the Model Context Protocol”, Dostęp zdalny (6.05.2026): <https://www.anthropic.com/news/model-context-protocol>, 2024.
- [2] OpenAI, “Dokumentacja API OpenAI”, Dostęp zdalny (7.05.2026): <https://developers.openai.com/api/docs/mcp>.
- [3] Anthropic, “Donating the Model Context Protocol and establishing the Agentic AI Foundation”, Dostęp zdalny (7.05.2026): <https://www.anthropic.com/news/donating-the-model-context-protocol-and-establishing-of-the-agentic-ai-foundation>, 2025.
- [4] Y. Lei i in., “A Comprehensive Survey on Model Context Protocol: Architecture, Tool Integration, and the Future of AI Interoperability”, Dostęp zdalny (9.05.2026): <https://ssrn.com/abstract=5957238>, 2025.

Spis załączników

1. Nazwa załącznika 1	6
2. Nazwa załącznika 2	6
3. Nazwa załącznika 3	6

Załącznik 1. Nazwa załącznika 1

Załącznik 2. Nazwa załącznika 2

Załącznik 3. Nazwa załącznika 3